


PROCESOS ETL



MSC. FERNANDO ZEBALLOS O.

ETL

Procedimientos (herramientas) destinados a obtener los datos de las fuentes operacionales, limpiarlos, convertirlos a los formatos de utilización y cargarlos en el repositorio final.




ETL son las siglas en inglés de **Extraer**, **Transformar** y **Cargar** (Extract, Transform and Load). Es el proceso que permite a las organizaciones mover datos desde múltiples fuentes, reformatearlos, limpiarlos y llevarlos a otra fuente de datos, en el contexto de BI a una bodega de datos (data mart o data warehouse) para analizarlos o en otro sistema de información para apoyar un proceso de negocio.

PASOS DE UN ETL

Extraer de múltiples fuentes como ERP, CRM, sistemas de información que proveen archivos en diferentes formatos (host, csv, XML).

Transformar en la estructura definida en la bodega y considerar validaciones sobre reglas de negocio, técnicas (duplicados, limpieza, integridad, nulos), normalización y homogeneización, cambios de formato, así como procesos de ordenación, filtrados, cruces y agregados.



Cargar en las estructuras de almacenamiento de la bodega. Puede ser realizado en procesos batch y ser de diferentes tipos: por lotes, por registro, totales, deltas incrementales, entre otros.

INTEGRIDAD DE DATOS

Los datos cumplen condiciones de integridad cuando se ajustan a todos los estándares de valor y completitud.

Todos los datos del DW son correctos

El DW está completo (no existen más datos fuera de él).

INTEGRIDAD DE DATOS

La credibilidad del DW depende de la integridad de sus datos

El uso del DW depende de la percepción de los usuarios y de la confianza que tengan en su contenido.


De la integridad de datos depende el éxito del proyecto.

CONTROLES DE INTEGRIDAD

Controles de Prevención : controlan la integridad antes de cargar los datos en el DW.

Controles de Detección : aseguran la exactitud y completitud de la información una vez cargada en el DW.

DATA PROCESS FLOW



Data Process Flow Stages:


- 1.Data Migration
- 2.Cleansing
- 3.Transformation
- 4.Loading
- 5.Reconciliation

ETAPAS DEL PROCESO ETL

- Migración de datos (extracción)
- Limpieza
- Transformación
(cálculos, agregados, sumalizaciones, desnormalización).
- Carga
- Conciliación - Validación

MIGRACIÓN (EXTRACCIÓN)

- **Staging Area** : área de trabajo fuera del DW.
- El propósito de la migración es mover los datos de los sistemas operacionales a las áreas de trabajo (staging áreas).
- NO se debe mover datos innecesarios (control preventivo).



VENTAJAS DE UTILIZAR UNA STAGING AREA

- **Permite independizar el proceso de carga por bloques o etapas. Lo cual es muy útil y práctico cuando se trabaja con millones de datos, ya que evita tener que reiniciar el proceso entero en caso de error o avería. Por ejemplo, si se produjese un corte eléctrico, solo habría que repetir el volcado de datos del bloque específico en el que se ha producido la incidencia, estando el resto de información a buen recaudo y segura en el área de staging.**
- **Si se implementa correctamente, posibilita reiniciar las distintas fases del proceso ETL de manera independiente. Esto significa que si, por ejemplo, falla el proceso de transformación, bastaría con volver a repetir esta fase, pero no sería necesario repetir la etapa anterior: la de extracción.**
- **La compilación de los distintos bloques o etapas del proceso de staging puede incluso adaptarse a las necesidades de los clientes, aunque siempre que esté contemplado previamente en el proceso general del ETL.**
- **Al tratarse de un disco físicamente independiente, en ningún caso afecta ni ralentiza otros procesos del sistema.**


LIMPIEZA (DATA CLEANING)

- **Corregir, estandarizar y completar los datos**
- **Identificar datos redundantes**
- **Identificar valores atípicos (outliers)**
- **Identificar valores perdidos (missings)**

LIMPIEZA (DATA CLEANING)

Es muy recomendable definir la limpieza de datos como una fase específica del proceso de ETL, debido a que esta actividad permite:

- Ahorrar tiempo
- Ganar en efectividad
- Unificar criterios



What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%



"Información consolidada, con datos correctos y con una visión única para todos los usuarios"

LIMPIEZA (ACTIVIDADES)

Se debe uniformar las tablas de códigos de los sistemas operacionales y simplificar esquemas de codificación

Datos complejos, que representan varios atributos a la vez, deben ser particionados.

TRANSFORMACIÓN

Son procesos destinados a adaptar los datos al modelo lógico del DW

Se generan “reglas de transformación”.

Las reglas deben validarse con los usuarios del DW

TRANSFORMACIÓN

**Generalmente el DW no contiene información de las entidades que
- en los sistemas operacionales - son muy dinámicas y sufren
frecuentes cambios.**

Si es necesario se utilizan Snapshots (fotos instantáneas)

TRANSFORMACIÓN

La des-normalización de los datos tiene como propósito mejorar la performance.

Otro propósito es el de reflejar relaciones estáticas, es decir, que no cambian en una perspectiva histórica. Por ejemplo: producto - precio vigente al momento de facturación.

TRANSFORMACIÓN (SUMARIZACIONES)

Los datos sumarizados aceleran los tiempos de análisis.

Las sumarizaciones también ocultan complejidad de los datos.

Las sumarizaciones pueden incluir joins de múltiples tablas


Las sumarizaciones proveen múltiples vistas del mismo conjunto de datos detallados (dimensiones).

EL LADO MÁS PRÁCTICO DEL PROCESO DE TRANSFORMACIÓN

En ocasiones será necesario realizar alguna pequeña manipulación de los datos, sin embargo, y dependiendo siempre de las fuentes de datos, a veces los que hará falta será aplicar algunas de las siguientes transformaciones:

- Seleccionar sólo ciertas columnas para su carga (por ejemplo, que las columnas con valores nulos no se carguen).
- Traducir códigos (por ejemplo, si la fuente almacena una “H” para Hombre y “M” para Mujer pero el destino tiene que guardar “1” para Hombre y “2” para Mujer).
- Codificar valores libres (por ejemplo, convertir “Hombre” en “H” o “Sr” en “1”).
- Obtener nuevos valores calculados (por ejemplo, $\text{total_venta} = \text{cantidad} * \text{precio}$).
- Unir datos de múltiples fuentes (por ejemplo, búsquedas, combinaciones, etc.).
- Calcular totales de múltiples filas de datos (por ejemplo, ventas totales de cada región).
- Generar campos clave en el destino.
- Transponer o pivotar (girando múltiples columnas en filas o viceversa).
- Dividir una columna en varias (por ejemplo, columna “Nombre: García, Miguel”; pasar a dos columnas “Nombre: Miguel” y “Apellido: García”).

ESTRUCTURA DIMENSIONAL



The star schema is the simplest representation of the dimensional data model.

Dimensional models support efficient system design and operation and help end users understand the possibilities of the system.

SUMARIZACIONES (MANTENIMIENTO)

El mantenimiento de las sumalizaciones es una tarea crítica.

El DW debe actualizarlas a medida que se cargan nuevos datos.

Debe existir alguna forma de navegar los datos hasta el nivel de detalle (drill down).

La definición de la granularidad es un problema serio de diseño.

EL NIVEL DE GRANULARIDAD: PROBLEMA DE DISEÑO DEL DW

Cuál es la unidad de tratamiento (fila)

¿Qué es un cliente? Una cuenta, un individuo, una familia

¿Cómo se sumariza la dimensión tiempo? Días, semanas, meses
...?

CARGA (LOADING)

Dos aproximaciones:

- Full Refresh
- Incremental

Aunque el Full Refresh parece más sólido desde el punto de vista de la integridad de los datos, a medida que crece el DW se vuelve cada vez más difícil de realizar.

FORMAS BÁSICAS DE DESARROLLAR EL PROCESO DE CARGA

- **Acumulación simple:** esta manera de cargar los datos consiste en realizar un resumen de todas las transacciones comprendidas en el período de tiempo seleccionado y transportar el resultado como una única transacción hacia el data warehouse, almacenando un valor calculado que consistirá típicamente en un sumatorio o un promedio de la magnitud considerada. Es la forma más sencilla y común de llevar a cabo el proceso de carga.
- **Rolling:** este proceso sería el más recomendable en los casos en que se busque mantener varios niveles de granularidad. Para ello se almacena información resumida a distintos niveles, correspondientes a distintas agrupaciones de la unidad de tiempo o diferentes niveles jerárquicos en alguna o varias de las dimensiones de la magnitud almacenada (por ejemplo, totales diarios, totales semanales, totales mensuales, etc.).

CONTROLES DE DETECCIÓN

La validación de la carga del DW identifica problemas en los datos no detectados en las etapas anteriores.

Existen dos maneras de hacer la validación:

- completa (al final del proceso)
- por etapas a medida que se cargan los datos

CONTROLES DE DETECCIÓN

Los controles incluyen reportes que comparan los datos del DW con las fuentes operacionales a través de:

- totales de control
- número de registros cargados
- valores originales vs valores limpios (transformados), etc.

BENEFICIOS DE UN BUEN PROCESO ETL

- Realizar un examen completo de la validez de los datos (**Data profiling / Data quality**), identificando las condiciones necesarias para que los datos puedan ser tratados adecuadamente por las reglas de transformación especificadas.
- Lograr que los datos extraídos asincrónicamente de orígenes heterogéneos, se integren finalmente en un **entorno homogéneo**.
- Asegurar la **escalabilidad** durante su vida útil (volumen de datos vs tiempo de procesamiento)



"Un sistema ETL mal diseñado, puede provocar importantes problemas operativos en el momento de analizar la información"

HERRAMIENTAS ETL



HERRAMIENTAS ETL

Las herramientas ETL ahorran tiempo y dinero cuando se tiene que desarrollar un Data Warehouse al reducir la cantidad de Sistemas de Conversión personalizados a desarrollar para migrar o concentrar al información.

Un proceso ETL puede llegar a ser muy complejo, también teniendo en cuenta el elevado tamaño de los datos para extraer, transformar y cargar. Por lo cual, las herramientas ETL juegan un papel fundamental ya que son la base para cualquier estrategia de análisis de datos y de inteligencia de negocio.

Existen herramientas que proporcionan interfaces visuales para definir joins, transformaciones, agregados, etc. sobre las plataformas mas comunes.

CATEGORÍAS DE HERRAMIENTAS ETL

Hay distintas herramientas ETL en el mercado, cada una con sus características concretas. Sin embargo, a la hora de elegir la herramienta adecuada para nuestra empresa o proyecto, nos encontramos frente a cuatro distintas categorías principales:

- **Herramientas ETL Enterprise.** Se trata de productos propietarios, con muchas funcionalidades incluidas y soporte para conexión con una gran cantidad de fuentes y suelen ser elegidas por grandes empresas ya que el coste de adquisición es elevado.
- **Herramientas ETL open source.** Se trata de herramientas de código libre y de uso gratuito, lo que permite una mayor accesibilidad para empresas de tamaño reducido. Al ser productos con un enfoque general, es necesaria a menudo una personalización para que se adapten a objetivos concretos, lo que requiere consultoría especializada.
- **Herramientas ETL personalizadas.** Se trata de herramientas desarrolladas a medida y de forma específica para una empresa o proyecto en concreto. Requieren un grande esfuerzo inicial de desarrollo, pero el resultado se ajusta mejor a los requerimientos.
- **Herramientas ETL Cloud.** La nube nos puede proporcionar todas sus ventajas como una alta flexibilidad y el pago por uso a la hora de elegir herramientas ETL que se ofrecen como servicio.

COMPARATIVA DE HERRAMIENTAS ETL

A continuación, vamos a ver las principales características según las cuales es posible realizar una comparativa de herramientas ETL:

- El **coste**, que no se limita únicamente el coste de adquisición, sino que también incluye el soporte, la formación y los costes de consultoría. Es importante tener en cuenta el total de estos costes para decidir entre una herramienta propietaria o de código libre.
- El **riesgo** de que el proyecto no tenga éxito, lo que incluye no cumplir con el presupuesto, con el calendario o con los requerimientos o expectativas de los clientes.
- La **facilidad de uso**, lo que se mejora de forma sustancial si la herramienta dispone de una interfaz gráfica amigable, lo que puede reducir también el tiempo de aprendizaje.
- El **soporte y la atención al cliente**. En este sentido hay que tener en cuenta si se ofrece en varios idiomas y países.

COMPARATIVA DE HERRAMIENTAS ETL

- Los **requerimientos de despliegue de la herramienta**, lo que incluye la compatibilidad con las distintas plataformas y sistemas operativos, así como los requisitos de sistema en cuanto a hardware.
- La **velocidad**, que depende en larga medida de la cantidad de datos que hay que transferir a través de la red y de la capacidad de cálculo requerida para las transformaciones.
- La **calidad de datos**, quizás la característica más importante de las herramientas ETL ya que permite disponer de datos validados y limpios.
- **Herramientas de control**, que permiten identificar y solucionar los problemas a lo largo de la fase de desarrollo y después.
- La **conectividad** con todo tipo de sistema, lo que nos puede permitir extraer datos de todo tipo de aplicaciones heredadas, sean base de datos, mainframes, ficheros planos, XML, Excel, etc.

HERRAMIENTAS ENTERPRISE

Informática PowerCenter	Este producto es posiblemente el producto de ETL más maduro del mercado . Es parte de una gran cartera de productos, incluida como plataforma de Informática. Informática es menos maduro que otros productos para fuentes semiestructuradas y no estructuradas
IBM Infosphere DataStage	A diferencia de muchas otras herramientas ETL, proporciona capacidades sólidas para trabajar con computadoras <i>mainframe</i>
Oracle Data Integrator	Utiliza una arquitectura diferenciada frente a otros productos. En lugar de realizar las transformaciones empleando el motor de la propia herramienta ETL, a través de los recursos de <i>hardware</i> , envía los datos al destino y luego realiza las transformaciones utilizando el motor de la base de datos
Microsoft SQL Server Integration Services -SSIS-	Tiene un costo menor que otras herramientas ETL empresariales y es bastante intuitiva y fácil de usar . Sin embargo, está limitada a implementaciones bajo el sistema operativo de Windows
SAP Data Services	Es una herramienta ETL diseñada principalmente para mover datos entre aplicaciones SAP. No tiene un uso amplio fuera de estos entornos
SAS Data Manager	SAS ha desarrollado un producto ETL con fuerte soporte para Hadoop, transmisión de datos y aprendizaje automático

HERRAMIENTAS OPEN SOURCE ETL

Talend
Open
Studio

Open Studio emplea código Java para el desarrollo y ejecución de los procesos ETL, enfoque que le da algunas ventajas de rendimiento y cierta libertad de programación para la construcción de los procesos

Pentaho
Data
Integration
-anterior
Kettle-

PDI es una herramienta ETL de código abierto ampliamente conocida por su interfaz gráfica Spoon. PDI exporta los procesos en archivos XML y estos son ejecutados a través de su motor ETL

Hadoop

Se trata de una plataforma distribuida empleada para almacenar, manipular y analizar datos de cualquier estructura. Es un ecosistema complejo de proyectos de código abierto que alberga más de 20 tecnologías diferentes. Algunos de estos sub-productos se utilizan para desarrollar tareas de ETL, como Pig, MapReduce y Spark

ETL PERSONALIZADA

Muchas compañías usan lenguajes de programación de propósito general para implementar sus propias herramientas de ETL. Esta opción aporta gran flexibilidad, pero también requiere un mayor esfuerzo, ya que se carece de las pautas que cualquier herramienta establece. Algunas herramientas:

Python

Python es un lenguaje de programación de propósito general. Se ha convertido en una herramienta popular para realizar tareas de ETL debido a su **facilidad de uso** y a las **múltiples bibliotecas** existentes para acceder a bases de datos y tecnologías de almacenamiento.

Java

Java es otro lenguaje de propósito general que se puede usar para construir el procesamiento de ETL. Java tiene un **amplio soporte** para diferentes fuentes de datos y transformación de los mismos.

Spark y Hadoop

Spark y Hadoop son *frameworks* que trabajan con **grandes conjuntos de datos** en grupos de computadoras. Facilitan la aplicación del potencial de muchas máquinas para realizar de forma paralela el procesamiento de la información. Esta capacidad permite evitar el procesamiento de una gran volumetría por una única máquina.

ETL COMO SERVICIOS EN LA NUBE

AWS EMR

Elastic MapReduce es la oferta de *Hadoop* proporcionada por AWS. Las empresas que usan *Hadoop* para implementar sus ETL, pueden optar por *EMR* para la ejecución en AWS. Al igual que con cualquier distribución de *Hadoop*, hay varias herramientas disponibles, incluidas *Hive* y *Spark*. Esta solución es potente, **escalable** y capaz de **trabajar con datos estructurados y no estructurados**.

AWS Glue

Es un servicio AWS totalmente administrado y está dirigido a **desarrolladores**. Se integra con otros servicios de Amazon, de almacenamiento como *S3*, *RDS* y *Redshift*, y de otros propósitos, como *Lambda*. *Glue* se puede conectar a **fuentes de datos locales** para migrar sus datos a la nube. Las ETL se escriben en *Python* y se ejecutan usando *Apache Spark* y *PySpark*.

Azure Data Factory

Data Factory es un servicio totalmente administrado que se conecta a una amplia gama de fuentes de datos tanto en la nube como en las instalaciones. Es capaz de **copiar, transformar y almacenar los datos** en los servicios destino de Azure. *Data Factory* también admite *Hadoop*, *Spark* así como **matching learning** para la transformación.

Google Cloud Dataflow

Dataflow es un servicio totalmente administrado dirigido a **desarrolladores** para el **diseño de trabajos** ETL continuos y por *batch*. *Dataflow* proporciona API para *Java* y *Python*. Los desarrolladores pueden así conectarse a las fuentes de *Google Cloud*, **aplicar transformaciones** y **guardar datos en otros destinos** de *Google Cloud*. Las API de *Dataflow* se basan en *Apache Beam*.

LAS MEJORES HERRAMIENTAS ETL

Si queremos saber cuáles son las mejores herramientas ETL, una referencia importante es el Cuadrante Mágico de Gartner, que cada año indica cuáles son los proveedores leader del mercado, entre los cuales se encuentran:

- **Informática:** líder según Gartner. Su suite empresarial de integración de datos incluye la solución PowerCenter, una de las más populares.
- **IBM:** proporciona la suite de soluciones InfoSphere, en la cual destaca su herramienta DataStage.
- **Talend:** conocido por su software de integración de código abierto gratuito Open Studio.
- **SAP:** ofrece la herramienta ETL Data Services como parte de SAP BO (Business Objects)
- **SAS:** proporciona una solución de integración de datos llamada Data Management
- **Oracle:** proporciona la herramienta ELT Data Integrator, que permite gestionar procesos de integración de datos en sistemas de inteligencia de negocio.

Informatica PowerCenter




- Informática tiene una muy buena suite empresarial de integración de datos.
- Fue fundada en el año de 1993.
- Líder actual del sector Data Integration (Gartner Dataquest).
- Tiene miles de clientes, entre los cuales figuran Bancos como Grupo BBVA, organizaciones Gubernamentales, etc.
- La compañía se enfoca meramente en soluciones para la integración de datos.

Talend




- ◆ Talend es una herramienta OpenSource para la integración de información.
- ◆ Usa un enfoque hacia la generación de código para la manipulación de información y posee una GUI implementada en Eclipse RC.
- ◆ Lanzó su primera versión en el año 2006.
- ◆ Genera código en Java o Scripts en Pearl que pueden ser implementados en servidores que lo soporten.
- ◆ Cuenta con una gran variedad de testimonios por parte de compañías importantes.




COSTO TOTAL DE DOMINIO

- ◆ Significa el costo promedio de cierto producto. Desde costo de orden, licencia, servicio, soporte, entrenamiento, consultoría y cualquier otro pago adicional, que se tenga que realizar para el uso total.
- ◆ Las herramientas OpenSource son naturalmente gratis de utilizar, pero el soporte, entrenamiento y consultoría son los costos a considerar.



FIN PROCESOS ETL



MSC. FERNANDO ZEBALLOS O.